

Context Engineering w systemach RAG

Zaawansowane zarządzanie kontekstem w domenie prawnej

NLP - Projekt

Zespół projektowy



Natalia Choszczyk



Filip Langiewicz



Mikołaj Rowicki

Agenda

1. Definicja problemu
2. Przegląd literatury
3. Architektura rozwiązania
4. Pipeline RAG — segmentacja, retrieval, reranking, kompresja
5. Aplikacja Streamlit
6. Ewaluacja — metryki i zestaw testowy
7. Wyniki eksperymentów
8. Eksperyment Lost-in-the-Middle
9. Wyniki Ragas
10. Wnioski końcowe

Definicja problemu



Długi kontekst

Dokumenty prawne >10 000 tokenów wymagają podziału na fragmenty z zachowaniem struktury i semantyki



Rozumienie zapytań

Pytania użytkowników w języku potocznym vs. formalny styl dokumentów prawnych



Kompresja kontekstu


Brak empirycznych podstaw porównania strategii: ekstrakcja vs. hierarchiczne podsumowania



Lost-in-the-Middle


Modele pomijają informacje ze środkowych części kontekstu — kluczowy problem w dokumentach prawnych

Przegląd literatury




RAG

Lewis et al. (2020) — Retrieval-Augmented Generation łączy LLM z wyszukiwaniem dokumentów




Chunking

Reuter et al. (2025) — Summary-Augmented Chunking wzbogaca fragmenty o globalne streszczenie




Query Rewriting

Ma et al. (2023) — Rewrite-Retrieve-Read reformuluje zapytania do formy zgodnej z dokumentami




Kompresja

Guo et al. (2025) — ACC-RAG adaptacyjnie kompresuje kontekst z hierarchicznym wyborem fragmentów



Cache

Jin et al. (2024) — RAGCache cache'uje fragmenty wiedzy redukując czas odpowiedzi



Lost-in-Middle

Liu et al. (2023) — modele pomijają informacje ze środka kontekstu; Zhang et al. (2025) — BriefContext (map-reduce)

Dane – dokumenty prawne



Dokument 1

Ustawa z dnia 20 maja 2016 r. o efektywności energetycznej

33 strony



Dokument 2

Rozporządzenie Ministra Klimatu z 7 kwietnia 2020 r. — taryfy i rozliczenia w ciepłownictwie

23 strony



Dokument 3

Ustawa z dnia 10 kwietnia 1997 r. — Prawo energetyczne

428 stron

Architektura rozwiązania

Pipeline RAG dla prawa energetycznego

Segmentacja dokumentów

Chunking strukturalny

- Podział wg artykułów i paragrafów
- Zachowanie informacji o nadrzędnym rozdziale
- Metadane: numer artykułu, rozdział, plik, strona
- Rekurencyjny podział zbyt długich fragmentów
- Mechanizm awaryjny dla dokumentów bez struktury

Chunking semantyczny

- SemanticChunker z LangChain Experimental
- Podział w miejscach zmiany znaczenia
- Dystans embeddingów sąsiednich zdań
- Scalanie zbyt krótkich fragmentów
- Model: paraphrase-multilingual-mpnet-base-v2

Pipeline RAG

1

Query Understanding

Rewriting zapytania do formalnej postaci prawnej za pomocą LLM

2

Retrieval

Wyszukiwanie semantyczne w Qdrant (parametryzowalny k, domyślnie 5)

3

Reranking

Kolejność oryginalna lub U-shape (istotne fragmenty na początku i końcu)

4

Kompresja kontekstu

Filtr ekstrakcyjny | Hierarchiczne streszczenie | BriefContext (map-reduce)

5

Generacja

Prompt wymuszający odpowiedź z kontekstu + odmowę przy braku informacji

Metody kompresji kontekstu

Filtr ekstrakcyjny

LLMChainExtractor analizuje każdy fragment osobno i usuwa nieistotne. Precyzyjny, ale agresywny — czasem zostawia pusty kontekst.

Hierarchiczne streszczenie

Dwukrokowy proces: (1) streszczenie każdego chunka w kontekście pytania, (2) agregacja streszczeń w jedno spójne podsumowanie.

BriefContext (map-reduce)

Podział fragmentów na 3 partycje → odpowiedź per partycja → agregacja. Mityguje lost-in-the-middle dzięki krótkim partycjom.

Semantic Cache

Mechanizm optymalizacji powtarzalnych zapytań



Próg konfiguralny w aplikacji suwakiem (0.70 – 1.00). Cache działa po stronie aplikacji.

Aplikacja Streamlit

Interfejs czatu z konfiguracją systemu w panelu bocznym

KONFIGURACJA SYSTEMU

SEGMENTACJA DOKUMENTÓW

Strukturalna

Semantyczna

PRZETWARZANIE ZAPYTAŃ

Przepisywanie zapytania

Bez transformacji

RERANKING

Kolejność oryginalna

Zmiana kolejności U-Shape

KOMPRESJA KONTEKSTU

Bez kompresjiFiltr ekstrakcyjnyStreszczenie hierarchiczne

MODEL JĘZYKOWY

Groq

WYSZUKIWANIE

Liczba fragmentów (k)

5

PAMIĘĆ PODRĘCZNA

Włącz pamięć podręczną

Próg podobieństwa

0.92

Doradca Energetyczny

ANALIZA PRZEPISÓW Z ZAKRESU ENERGETYKI

Jakie koszty przyjąć do kalkulacji taryfy dla ciepła?Zgodnie z dokumentem [2] § 17, koszty, które należy uwzględnić w kalkulacji taryfy dla ciepła, obejmują:

1. Koszty stałe i zmienne wytwarzania, przetwarzania i magazynowania ciepła.

2. Planowane roczne koszty modernizacji, rozwoju i ochrony środowiska.

3. Koszty utrzymania zapasów paliw.

4. Koszty utrzymania przewidzianych w programie pracy sieci ciepłowniczych źródeł ciepła.

5. Koszty handlowej obsługi odbiorców bezpośrednio zasilanych ze źródeł ciepła.

6. Koszty stałe i zmienne pozyskania, uzdatniania i podgrzewania nośnika ciepła.

7. Koszty stałe i zmienne przesyłania i dystrybucji ciepła.

8. Koszty handlowej obsługi odbiorców.

Ponadto, zgodnie z dokumentem [3] § 15, należy uwzględnić koszty uzasadnione realizacji obowiązku, o którym mowa w art. 10 ust. 1 ustawy z dnia 20 maja 2016 r. o efektywności energetycznej.

Szczegóły odpowiedzi

Konfiguracja: query_transform=QueryRewriter | reranking=OriginalOrderReranker | compression=none

Źródła:

document3.pdf | strona 366 | Art. 45. | Rozdział 5 Koncesje, rejestry i taryfy...

document2.pdf | strona 8 | § 17. | Rozdział 3 Szczegółowe zasady kalkulacji cen i stawek opłat...

document2.pdf | strona 8 | § 15. | Rozdział 3 Szczegółowe zasady kalkulacji cen i stawek opłat...

document2.pdf | strona 14 | § 29. | Rozdział 3 Szczegółowe zasady kalkulacji cen i stawek opłat...

Zadaj pytanie dotyczące dokumentów prawnych...

Ewaluacja

Metryki, zestaw testowy, konfiguracja eksperymentów

Metryki ewaluacji

LLM-as-a-Judge (Gemini 2.5 Flash)

- **Faithfulness** — Czy stwierdzenia wynikają z kontekstu? (1–5)
- **Answer Relevance** — Czy odpowiedź odnosi się do pytania? (1–5)
- **Completeness** — Czy odpowiedź jest pełna i merytoryczna? (1–5)

Ragas — walidacja kontekstu

- **Context Precision** — Czy zwrócone fragmenty są istotne? (0–1)
- **Context Relevance** — Jaki odsetek treści odnosi się do pytania? (0–1)

Sędzia LLM-as-a-Judge celowo inny od modelu generatywnego (Gemini vs Llama) — uniknięcie self-preference bias

Zestaw testowy

Krótkie (S)

S1: Jakie koszty przyjąć do kalkulacji taryfy dla ciepła?

S2: Jak ocenia się koszty uzasadnione przyjęte do taryfy?

S3: Jak ustala się koszt zakupu uprawnień do emisji CO₂?

S4: Jak określić współczynnik udziału opłat stałych?

Długie (L)

L1: Jak wyliczyć kwotę zwrotu z kapitału w taryfie?

L2: Co należy przedstawić we wniosku o zatwierdzenie taryfy?

L3: Czy spółka dostarczająca ciepło musi stosować bonifikatę przy awarii?


Negatywne (N)

N1: Stawka VAT na energię ciepłą w 2024?


N2: Średnia cena ciepła systemowego w Polsce w 2024?

N3: Jak rozliczyć podatek od nadwyżki z fotowoltaiki?


Jakość odpowiedzi wg konfiguracji




Trade-off: jakość vs koszt tokenów




Latencja per konfiguracja




Zużycie tokenów



Completeness – heatmapa




Completeness wg kategorii pytań



Podsumowanie wyników

Config	F	R	C	Lat[s]	CtxTok	AnsTok	N
Baseline (structure)	5.00	5.00	4.60	0.72	698	21	10
Semantic chunking	5.00	5.00	4.20	7.18	1633	17	10
U-shape reranking	5.00	4.80	4.80	0.70	698	21	10
Query rewriting	4.80	5.00	4.20	1.24	721	44	10
Extractive compression	5.00	5.00	5.00	2.14	106	35	10
Hierarchical compression	5.00	4.80	4.40	3.63	98	54	10
Full stack	5.00	4.60	4.50	4.01	92	54	10
Brief Context	5.00	4.80	4.80	2.70	26	10	10

Wyniki Ragas — jakość retriewa




Uwaga: Precision = 1.00 dla konfiguracji z kompresją wynika z faktu, że Ragas ocenia zsyntetyzowany fragment, nie oryginalny retrieval. Context Relevance jest bardziej miarodajne.


Eksperyment Lost-in-the-Middle

Kontrolowane badanie wpływu pozycji kluczowego fragmentu na jakość odpowiedzi

Lost-in-the-Middle – completeness vs pozycja



Lost-in-the-Middle – per pytanie × metoda



BriefContext osiąga najwyższą średnią completeness (3.87), wyprzedzając U-shape (3.67) i brak mitygacji (3.27). Metody są komplementarne: U-shape jest tańsza obliczeniowo, BriefContext stabilniejszy.

Wnioski końcowe

- Chunking strukturalny przewyższa semantyczny pod względem jakości i kosztu
- Query rewriting nie pomaga, gdy pytania są już sformułowane formalnym językiem
- Kompresja kontekstu drastycznie zmniejsza koszt tokenowy bez istotnej utraty jakości
- BriefContext — najlepszy stosunek jakości do kosztu i najskuteczniejsza mitygacja LitM
- System odporny na halucynacje — prompt wymuszający odmowę działa skutecznie
- Baseline (chunking strukturalny, brak rerankingu, brak kompresji) jest zaskakująco mocny
- Completeness to kluczowa metryka — bez niej różnice między konfiguracjami są niewidoczne

Bibliografia

- [1] Lewis et al. (2020) — Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
- [2] Reuter et al. (2025) — Towards Reliable Retrieval in RAG Systems for Large Legal Datasets
- [3] Ma et al. (2023) — Query Rewriting for Retrieval-Augmented Large Language Models
- [4] Wu et al. (2022) — CONQRR: Conversational Query Rewriting for Retrieval with RL
- [5] Guo et al. (2025) — Enhancing RAG Efficiency with Adaptive Context Compression
- [6] Cheng et al. (2024) — xRAG: Extreme Context Compression with One Token
- [7] Ou & Lapata (2025) — Context-Aware Hierarchical Merging for Long Document Summarization
- [8] Jin et al. (2024) — RAGCache: Efficient Knowledge Caching for RAG
- [9] Liu et al. (2023) — Lost in the Middle: How Language Models Use Long Contexts
- [10] Zhang et al. (2025) — A MapReduce Approach to Effectively Utilize Long Context in RAG

Dziękujemy za uwagę!

Natalia Choszczyk | Filip Langiewicz | Mikołaj Rowicki

2026